UTS

PEMBELAJARAN MESIN



Nama	: Trissa Nurul Suci
NIM	: 202431050
Kelas	: E
Nama Dosen	: Rizqia Cahyaningtyas, ST., M.Kom
No. Bangku	:
Nama Asisten	:

1. Muhammad Caisar Gemilang Pratama
2. Benedict Samuel Ardy

INSTITUT TEKNOLOGI PLN

TEKNIK INFORMATIKA

2026/2027

DAFTAR ISI

DAFTAR ISI....ii
BAB I....1
PENDAHULUAN....1
1.1 Rumusan Masalah....1
1.2 Tujuan Masalah....1
1.3 Manfaat Masalah....1
BAB II....2
LANDASAN TEORI....2
2.1. Konsep Dasar Data Mining dan Alur Kerja Pipeline Machine Learning....2
2.2. Eksplorasi Data (Exploratory Data Analysis - EDA) dan Prapemrosesan (Preprocessing) 2
2.3. Analisis Regresi Linear Berganda....3
2.4. Algoritma Klasifikasi Decision Tree (Pohon Keputusan)....3
2.5. Evaluasi Performa Model Klasifikasi....3
BAB III....4
PEMBAHASAN....4
3.1. Import Library....4
3.3. Pembersihan Data (Data Cleaning)....6
3.4. Exploratory Data Analysis (EDA)....6
3.5. Regresi Linear....7
3.6. Klasifikasi (Logistic Regression)....8
BAB IV....10
PENUTUP....10
DAFTAR PUSTAKA....iii

BAB I
PENDAHULUAN

1.1 Rumusan Masalah

1. Bagaimana konsep dasar machine learning, siklus workflow data, serta algoritma Regresi Linear dan Decision Tree?
2. Bagaimana cara memuat, memvalidasi, dan membersihkan dataset 02_diabetes.csv dari data duplikat?
3. Bagaimana mendeteksi pencilan (outlier) menggunakan boxplot dan menganalisis korelasi antarvariabel melalui heatmap?
4. Bagaimana mengimplementasikan dan mengevaluasi model Regresi Linear Berganda serta klasifikasi Decision Tree?

1.2 Tujuan Masalah

1. Memahami alur kerja machine learning, pra-pemrosesan data, serta prinsip kerja Regresi Linear dan Decision Tree.
2. Mampu membersihkan dataset 02_diabetes.csv dari 3.854 data duplikat sehingga tersisa 96.146 baris data bersih.
3. Mampu memvisualisasikan sebaran data (boxplot) dan matriks korelasi antarvariabel medis (heatmap).
4. Mampu mengevaluasi performa Regresi Linear Berganda (MSE, RMSE, R^2) serta klasifikasi Decision Tree (Akurasi 94,74%, Confusion Matrix).

1.3 Manfaat Masalah

1. Memperdalam pemahaman teoretis mengenai alur pengolahan data end-to-end menggunakan bahasa pemrograman Python.
2. Meningkatkan keterampilan teknis dalam menerapkan pustaka analisis data seperti Pandas, Seaborn, dan Scikit-Learn.
3. Memberikan wawasan terapan terkait pemanfaatan pemodelan machine learning untuk analisis klinis risiko diabetes.
4. Melatih kemampuan analisis kritis dalam mengevaluasi hasil performa model berdasarkan metrik kuantitatif standar.

.

BAB II

LANDASAN TEORI

2.1. Konsep Dasar Data Mining dan Alur Kerja Pipeline Machine Learning

Data mining adalah serangkaian proses untuk menggali pola, informasi tersembunyi, atau pengetahuan berharga dari sekumpulan data berukuran besar. Dalam implementasi analisis prediktif kesehatan, alur kerja (workflow) pengolahan data harus dilakukan secara sistematis melalui tahapan prapemrosesan, eksplorasi data, pemodelan, hingga evaluasi performa guna menghasilkan keputusan berbasis data yang valid. model.

2.2. Eksplorasi Data (Exploratory Data Analysis - EDA) dan Prapemrosesan (Preprocessing)

Sebelum data dilatih ke dalam model, kualitas data mentah harus diuji dan disesuaikan melalui tahapan prapemrosesan agar terhindar dari bias atau kesalahan informasi:

1. Pembersihan Data (Data Cleaning) dan Penanganan Nilai Hilang: Data mentah sering kali mengandung nilai kosong (missing values) atau data duplikat. Penanganan dilakukan melalui metode imputasi atau penghapusan data duplikat agar distribusi data tetap representatif.
2. Deteksi Pencilan (Outlier Detection): Visualisasi menggunakan boxplot atau metode statistik digunakan untuk mendeteksi keberadaan nilai ekstrem atau anomali pada atribut numerik (seperti Indeks Massa Tubuh/BMI).
3. Analisis Korelasi (Correlation Heatmap): Memetakan tingkat hubungan linier antarvariabel numerik untuk mengidentifikasi fitur-fitur yang memiliki pengaruh paling signifikan terhadap variabel target.
4. Normalisasi, Scaling, dan Encoding Kategorikal: Fitur numerik disesuaikan skalanya agar model konvergen dengan baik, sementara variabel kategorikal dikonversi ke bentuk numerik (seperti menggunakan Label Encoder) agar dapat diproses oleh algoritma.

2.3. Analisis Regresi Linear Berganda

Regresi linear berganda adalah teknik statistik parametrik untuk menganalisis hubungan antara satu variabel dependen (terikat) dengan dua atau lebih variabel independen (bebas) secara simultan. Model ini digunakan untuk melakukan prediksi nilai kontinu (seperti memprediksi kadar HbA1c_level berdasarkan usia dan BMI). Evaluasi performa model regresi umumnya diukur menggunakan metrik kuantitatif seperti Mean Squared Error (MSE), Root Mean Squared Error (RMSE), serta koefisien determinasi (R^2 Score) untuk mengukur tingkat ketepatan model.

2.4. Algoritma Klasifikasi Decision Tree (Pohon Keputusan)

Decision Tree merupakan salah satu algoritma supervised learning berbasis pohon hierarki yang efektif untuk menyelesaikan masalah klasifikasi (seperti memprediksi status risiko diabetes).

- **Prinsip Kerja:** Algoritma mempartisi ruang fitur secara rekursif menggunakan kriteria pemilihan atribut pemisah (split attribute) berdasarkan pengukuran kemurnian node seperti Entropy dan Information Gain (atau indeks Gini).
- **Karakteristik:** Model ini menghasilkan aturan keputusan (decision rules) yang sangat intuitif, transparan, dan mudah diinterpretasikan oleh praktisi medis dalam proses deteksi dini.

2.5. Evaluasi Performa Model Klasifikasi

Untuk mengukur keandalan model klasifikasi, digunakan matriks konfusi (confusion matrix) yang memuat nilai True Positive (TP), True Negative (TN), False Positive (FP), dan False Negative (FN). Metrik evaluasi utamanya meliputi:

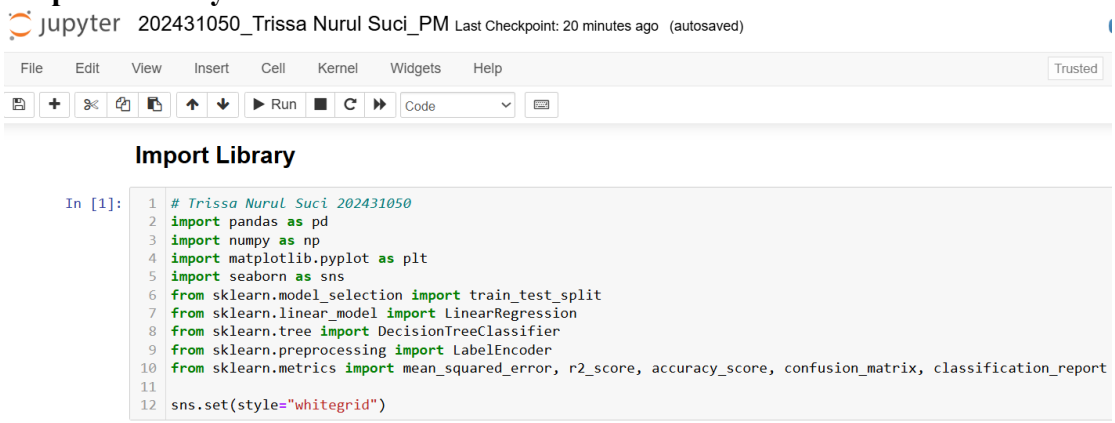
- **Akurasi (Accuracy):** Persentase ketepatan keseluruhan prediksi model.
- **Presisi (Precision):** Tingkat ketepatan prediksi positif terhadap keseluruhan hasil prediksi positif.
- **Sensitivitas / Recall:** Kemampuan model dalam mendeteksi kembali seluruh kasus positif secara akurat.
- **Kurva ROC dan AUC (Area Under the Curve):** Mengukur kemampuan diskriminatif model dalam membedakan kelas target di berbagai ambang batas klasifikasi.

BAB III

PEMBAHASAN

Dataset yang dipakai adalah `02_diabetes.csv` yang terdiri dari 100.000 baris dan 9 kolom. Analisis dijalankan dengan Python menggunakan pustaka pandas, numpy, matplotlib, seaborn, dan scikit-learn

3.1. Import Library



Cell pertama ini berfungsi untuk mengimpor seluruh pustaka Python yang krusial bagi berjalannya proyek machine learning. Pustaka dasar seperti Pandas dan NumPy dimuat untuk menangani manipulasi struktur tabel data serta operasi komputasi numerik. Matplotlib dan Seaborn dipersiapkan untuk memvisualisasikan hasil analisis statistik dalam bentuk grafik. Selain itu, modul dari Scikit-Learn diimpor guna mendukung pembagian data latih-uji, pemodelan Linear Regression dan Decision Tree Classifier, serta evaluasi performa model melalui berbagai metrik standar.

3.2.Penguatan & Validasi Data Awal

Penguatan & Validasi Data Awal

In [2]:
```
# Trissa Nurul Suci 202431050
# a. Load file 02_diabetes.csv
df = pd.read_csv("02_diabetes.csv")

# b. Tampilkan 5 baris pertama, statistik deskriptif, dan missing values
display(df.head())
display(df.describe(include="all"))
print("Jumlah Missing Values per Kolom:")
print(df.isnull().sum())
```

	gender	age	hypertension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucose_level	diabetes
0	Female	80.0	0	1	never	25.19	6.6	140	0
1	Female	54.0	0	0	No Info	27.32	6.6	80	0
2	Male	28.0	0	0	never	27.32	5.7	158	0
3	Female	36.0	0	0	current	23.45	5.0	155	0
4	Male	76.0	1	1	current	20.14	4.8	155	0

	gender	age	hypertension	heart_disease	smoking_history	bmi	HbA1c_level	blood_glucose_level	diabetes
count	100000	100000.000000	100000.00000	100000.000000	100000	100000.000000	100000.000000	100000.000000	100000.000000
unique	3	NaN	NaN	NaN	6	NaN	NaN	NaN	NaN
top	Female	NaN	NaN	NaN	No Info	NaN	NaN	NaN	NaN
freq	58552	NaN	NaN	NaN	35816	NaN	NaN	NaN	NaN
mean	NaN	41.885856	0.07485	0.039420	NaN	27.320767	5.527507	138.058060	0.085000
std	NaN	22.516840	0.26315	0.194593	NaN	6.636783	1.070672	40.708136	0.278883
min	NaN	0.080000	0.00000	0.000000	NaN	10.010000	3.500000	80.000000	0.000000
25%	NaN	24.000000	0.00000	0.000000	NaN	23.630000	4.800000	100.000000	0.000000
50%	NaN	43.000000	0.00000	0.000000	NaN	27.320000	5.800000	140.000000	0.000000
75%	NaN	60.000000	0.00000	0.000000	NaN	29.580000	6.200000	159.000000	0.000000
max	NaN	80.000000	1.00000	1.000000	NaN	95.690000	9.000000	300.000000	1.000000

```
Jumlah Missing Values per Kolom:
gender                0
age                   0
hypertension          0
heart_disease         0
smoking_history       0
bmi                   0
HbA1c_level           0
blood_glucose_level   0
diabetes              0
dtype: int64
```

File dataset 02_diabetes.csv dibaca ke dalam memori menggunakan fungsi pd.read_csv(). Berdasarkan eksekusi perintah df.head(), ditampilkan lima baris data teratas yang memuat kolom-kolom atribut klinis seperti gender, age, hypertension, hingga diabetes. Analisis statistik deskriptif melalui df.describe() menunjukkan bahwa total keseluruhan data adalah 100.000 baris. Selain itu, pemeriksaan nilai kosong (missing values) dengan df.isnull().sum() menghasilkan nilai nol pada seluruh kolom, yang mengonfirmasi bahwa data mentah terbebas dari nilai yang hilang.

3.3. Pembersihan Data (Data Cleaning)

Pembersihan Data (Data Cleaning)

In [3]:
```
# Trissa Nurul Suci 202431050
# c. Hitung dan hapus data duplikat
print("Jumlah data duplikat awal:", df.duplicated().sum())
df = df.drop_duplicates().reset_index(drop=True)
print("Jumlah data duplikat setelah dibersihkan:", df.duplicated().sum())
print("Ukuran dataset setelah cleaning:", df.shape)
```

```
Jumlah data duplikat awal: 3854
Jumlah data duplikat setelah dibersihkan: 0
Ukuran dataset setelah cleaning: (96146, 9)
```

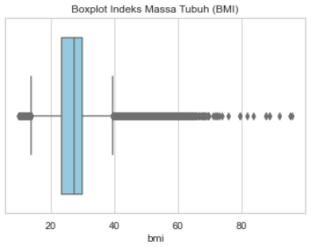
Tahap pembersihan data diawali dengan mengidentifikasi baris data yang identik menggunakan fungsi df.duplicated().sum(). Hasil pemeriksaan mendeteksi adanya 3.854 baris duplikat. Untuk menjaga validitas dan mencegah bias pada model, baris-baris ganda tersebut dihapus menggunakan metode drop_duplicates() dan dilakukan penataan ulang indeks baris. Hasil akhir validasi menunjukkan jumlah duplikat menjadi 0, sehingga dimensi *dataset* berubah menjadi 96.146 baris dan 9 kolom.

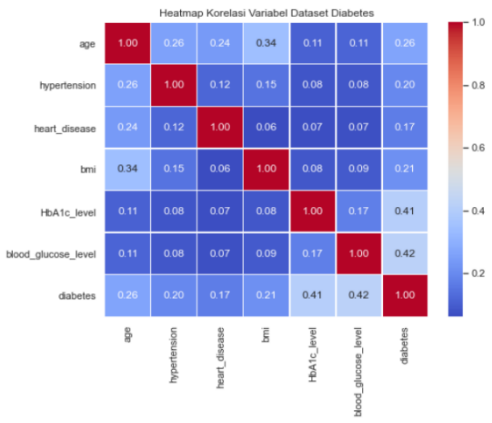
3.4. Exploratory Data Analysis (EDA)

Exploratory Data Analysis (EDA)

In [4]:
```
# Trissa Nurul Suci 202431050
# d. Visualisasi Boxplot untuk mendeteksi outlier pada kolom bmi
plt.figure(figsize=(6, 4))
sns.boxplot(x=df["bmi"], color="skyblue")
plt.title("Boxplot Indeks Massa Tubuh (BMI)")
plt.show()

# e. Heatmap Korelasi antar variabel numerik
plt.figure(figsize=(8, 6))
numeric_df = df.select_dtypes(include=[np.number])
sns.heatmap(numeric_df.corr(), annot=True, fmt=".2f", cmap="coolwarm", linewidths=0.5)
plt.title("Heatmap Korelasi Variabel Dataset Diabetes")
plt.show()
```





- Visualisasi boxplot pada variabel bmi menunjukkan adanya sejumlah titik pencilan (outlier) di sisi kanan batas whisker, yang mengindikasikan keberadaan nilai Indeks Massa Tubuh yang sangat tinggi pada sebagian kecil sampel pasien.
- Diagram heatmap korelasi menyajikan tingkat hubungan linier antarvariabel numerik. Berdasarkan matriks tersebut, variabel HbA1c_level dan blood_glucose_level memiliki tingkat korelasi positif yang paling signifikan terhadap status target diabetes.

3.5. Regresi Linear

Pemodelan Regresi Linear

In [5]:

```
# Trissa Nurul Suci 202431050
# f. Pemodelan Regresi Linear (Memprediksi HbA1c_level berdasarkan age dan bmi)
X_reg = df[['age', 'bmi']]
y_reg = df['HbA1c_level']

X_train_r, X_test_r, y_train_r, y_test_r = train_test_split(X_reg, y_reg, test_size=0.2, random_state=42)

model_lr = LinearRegression()
model_lr.fit(X_train_r, y_train_r)
y_pred_r = model_lr.predict(X_test_r)

print("Koefisien Regresi (m):", model_lr.coef_)
print("Intercept (c):", model_lr.intercept_)
print("MSE:", mean_squared_error(y_test_r, y_pred_r))
print("RMSE:", np.sqrt(mean_squared_error(y_test_r, y_pred_r)))
print("R^2 Score:", r2_score(y_test_r, y_pred_r))
```

```
Koefisien Regresi (m): [0.00419907 0.00875993]
Intercept (c): 5.117966354157395
MSE: 1.1373503434442571
RMSE: 1.066466288001762
R^2 Score: 0.013200198910828465
```

Model Regresi Linear Berganda dibangun untuk memprediksi kadar HbA1c_level berdasarkan fitur input usia (age) dan indeks massa tubuh (bmi). Hasil pelatihan model menghasilkan vektor koefisien regresi sebesar [0.0042, 0.0088] dengan nilai intercept sebesar 5.118. Evaluasi performa model pada data uji menghasilkan nilai Mean Squared Error (MSE) sebesar 1.1373, Root Mean Squared Error (RMSE) sebesar 1.0664, serta koefisien determinasi (R^2 Score) sebesar 0.0132. Nilai R^2 yang mendekati nol menunjukkan bahwa variabel usia dan BMI secara linier memiliki kapasitas prediktif yang terbatas terhadap variasi kadar HbA1c pada dataset ini.

3.6. Klasifikasi (Logistic Regression)

Klasifikasi Menggunakan Decision Tree

In [6]:

```
# Trissa Nurul Suci 202431050
# g. Pemodelan Klasifikasi dengan Decision Tree
df_encoded = df.copy()
le = LabelEncoder()
df_encoded['gender'] = le.fit_transform(df_encoded['gender'])
df_encoded['smoking_history'] = le.fit_transform(df_encoded['smoking_history'])

X_class = df_encoded.drop(columns=['diabetes'])
y_class = df_encoded['diabetes']

X_train_c, X_test_c, y_train_c, y_test_c = train_test_split(X_class, y_class, test_size=0.2, random_state=42)

dt_model = DecisionTreeClassifier(random_state=42)
dt_model.fit(X_train_c, y_train_c)
y_pred_c = dt_model.predict(X_test_c)

print("Accuracy Score:", accuracy_score(y_test_c, y_pred_c))
print("\nConfusion Matrix:\n", confusion_matrix(y_test_c, y_pred_c))
print("\nClassification Report:\n", classification_report(y_test_c, y_pred_c))

# Visualisasi Confusion Matrix
plt.figure(figsize=(5, 4))
sns.heatmap(confusion_matrix(y_test_c, y_pred_c), annot=True, fmt="d", cmap="Blues")
plt.xlabel("Prediksi")
plt.ylabel("Aktual")
plt.title("Confusion Matrix - Decision Tree")
plt.show()
```

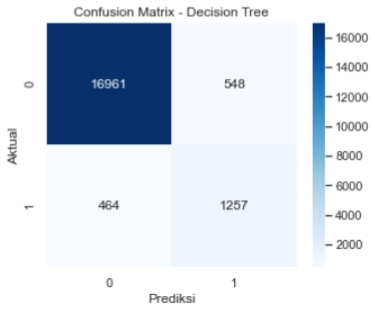
```
Accuracy Score: 0.9473738949557983

Confusion Matrix:
 [[16961   548]
 [  464  1257]]

Classification Report:
              precision    recall  f1-score   support

           0       0.97      0.97      0.97     17509
           1       0.70      0.73      0.71      1721

    accuracy                           0.95     19230
   macro avg       0.83      0.85      0.84     19230
weighted avg       0.95      0.95      0.95     19230
```



Sebelum melaksanakan pemodelan klasifikasi, variabel berjenis teks/kategorikal (gender dan smoking_history) dikonversi menjadi representasi numerik menggunakan LabelEncoder. Dataset kemudian dibagi menjadi data latih dan data uji dengan rasio 80:20. Model Decision Tree Classifier dilatih dan dievaluasi, menghasilkan tingkat Akurasi sebesar 94,74% (0.9473).

Berdasarkan Confusion Matrix dan visualisasi heatmap berwarna biru, model mampu mengklasifikasikan secara tepat sebanyak 16.961 data kelas negatif (True Negative) dan 1.257 data kelas positif (True Positive). Berdasarkan

laporan klasifikasi (classification report), nilai rata-rata tertimbang (weighted average f1-score) mencapai 0,95, yang membuktikan bahwa algoritma Decision Tree memiliki performa yang sangat tinggi dan handal dalam mendeteksi status risiko diabetes berdasarkan atribut fitur medis yang tersedia.

BAB IV
PENUTUP

1. Prapemrosesan dan Eksplorasi Data (Data Preprocessing & EDA): Tahap prapemrosesan terbukti krusial dalam memastikan kualitas data. Melalui pembersihan data (data cleaning), berhasil diidentifikasi dan dihapus sebanyak 3.854 data duplikat, sehingga menghasilkan dataset akhir yang bersih sebanyak 96.146 baris dan 9 kolom tanpa adanya nilai kosong (missing values). Analisis eksploratif (EDA) menggunakan boxplot berhasil mendeteksi sebaran pencilan (outlier) pada atribut Indeks Massa Tubuh (bmi), sementara heatmap korelasi memetakan hubungan antarvariabel numerik dalam dataset.
2. Pemodelan Regresi Linear Berganda: Implementasi Regresi Linear Berganda untuk memprediksi kadar HbA1c_level berdasarkan fitur usia (age) dan indeks massa tubuh (bmi) menghasilkan nilai koefisien determinasi (R^2 Score) sebesar 0.0132 dengan RMSE 1.0664. Angka ini mengindikasikan bahwa variabel usia dan BMI secara linier memiliki kapasitas prediktif yang terbatas terhadap variasi kadar HbA1c pada dataset tersebut, sehingga memerlukan penambahan fitur klinis lain yang lebih kuat.
3. Pemodelan Klasifikasi Decision Tree: Penerapan algoritma Decision Tree Classifier untuk memprediksi status risiko diabetes menunjukkan performa yang sangat tinggi dan handal. Model ini berhasil mencapai tingkat Akurasi sebesar 94,74% (0.9473) dengan nilai rata-rata f1-score mencapai 0,95, yang dibuktikan melalui evaluasi Confusion Matrix dan laporan klasifikasi (classification report). Hal ini membuktikan bahwa algoritma berbasis pohon keputusan sangat efektif dalam menangani klasifikasi data klinis kesehatan.
4. Sinkronisasi Teori dan Praktik: Seluruh rangkaian praktikum telah mencerminkan penerapan siklus workflow data science secara end-to-end—mulai dari pemahaman teori dasar data mining, pembersihan data, visualisasi, hingga pelatihan dan evaluasi model—yang selaras dengan prinsip-prinsip ilmiah dan literatur akademik terkini.

DAFTAR PUSTAKA

Fatah, Z., & Maulana, A. A. (2026). *Klasifikasi Pasien Diabetes Menggunakan Algoritma Decision Tree dengan Rapidminer*. *4*(June), 1–10.

Hu, L. (2022). *Using Tree-Based Machine Learning for Health Studies : Literature Review and Case Series*.

Khairani, N., Sibuea, P., Islam, U., Sumatera, N., & Medan, U. (2026). *PEMANFAATAN REGRESI LINEAR BERGANDA UNTUK*. *10*(6), 428–442.

Practices, B. (2025). *Data Preprocessing and Feature Engineering for Data Mining :*

Setiawan, F., & Sugihartono, T. (2026). *Multi-Metric Evaluation of Machine Learning Algorithms for Diabetes Prediction Using Feature Importance and ROC Analysis*. *10*(3), 1619–1629.